



École des Sciences de l'Information (ESI)
Filière : Ingénierie des Systèmes d'Information et Transformation Digitale (ISITD)

Rapport d'avancement

Sprint 3

SkillSeek AI

Plateforme intelligente de gestion du recrutement
Analyse automatique des CV et classement des candidatures

Auteur : Aymen Benbib

Organisme d'accueil : BC SKILLS

Table des matières

1	Objet du rapport	2
2	Rappel des sprints précédents	2
3	Synthèse de l'avancement	2
3.1	État global	2
3.2	Tâches du Sprint 3	3
3.3	Indicateurs de réalisation	3
4	Chaîne d'analyse d'une candidature	3
4.1	Vue d'ensemble	3
4.2	Lecture du document	4
4.3	Reconstitution du profil	4
4.4	Calcul de la note	4
4.5	Comportement en cas d'échec	5
5	La plateforme en fonctionnement	5
5.1	Espace du recruteur	5
5.2	Explication d'une note	6
5.3	Assistant et gestion des offres	8
5.4	Espace du candidat	9
5.5	Espace d'administration	10
5.6	Accessibilité	11
6	Choix structurants et justifications	11
6.1	Renoncement à l'apprentissage supervisé	11
6.2	Adoption des conventions professionnelles d'analyse de CV	12
6.3	Renforcement de la gouvernance des comptes	12
7	Vérification	12
8	Planification	13
8.1	Contenu du Sprint 4	13
9	Risques et mesures	13
10	Conclusion	13

1 Objet du rapport

Ce document présente l'état d'avancement du projet **SkillSeek AI** à la clôture du Sprint 3, consacré au cœur analytique de la plateforme : la lecture automatique des curriculum vitæ et le classement explicable des candidatures. Il rappelle brièvement les acquis des sprints précédents, détaille les réalisations de la période en les illustrant par des captures de la plateforme en fonctionnement, et expose la planification jusqu'à la livraison finale.

2 Rappel des sprints précédents

Le **Sprint 1** a livré le socle technique : environnement conteneurisé, chaîne d'intégration continue, modèle de données, authentification par jeton et contrôle d'accès par rôles appliqué en temps réel.

Le **Sprint 2** a livré l'interface complète — seize écrans répartis entre les trois profils d'utilisateurs — ainsi que les parcours métier de bout en bout et un système de notifications événementielles rendant perceptible la séparation des attributions.

Aucun de ces deux socles n'a nécessité de reprise durant le Sprint 3 : les points d'accès prévus pour recevoir l'analyse automatique ont été alimentés sans modification de leur interface.

3 Synthèse de l'avancement

3.1 État global

Sprint	Période	État	Périmètre
Sprint 1	06/07 – 15/07	Terminé	Socle technique, base de données, sécurité
Sprint 2	16/07 – 27/07	Terminé	Interface, parcours métier, notifications
Sprint 3	28/07 – 06/08	Terminé	Analyse des CV, classement explicable
Sprint 4	07/08 – 16/08	À venir	Décisionnel Power BI, indicateurs, finalisation

Avancement global estimé : **85 %** du périmètre fonctionnel. La plateforme est opérationnelle de bout en bout : un candidat dépose son curriculum vitæ, celui-ci est lu et analysé automatiquement, et le recruteur consulte un classement dont chaque note est justifiée.

3.2 Tâches du Sprint 3

ID	Tâche	Livrable vérifié	État
S3-01	Extraction du texte	Lecture directe des PDF, reconnaissance optique en repli, prise en charge des documents Word	OK
S3-02	Analyse linguistique	Découpage en sections, référentiel de 45 compétences avec variantes	OK
S3-03	Moteur de règles	Critères éliminatoires tracés avec leur motif exact	OK
S3-05	Proximité sémantique	Plongements lexicaux multilingues, repli lexical	OK
S3-08	Intégration	Analyse automatique au dépôt, réanalyse à la demande	OK
S3-09	Profil structuré	Schéma normalisé : identité, postes datés, formations, certifications, langues	OK
S3-10	Qualification en deux niveaux	Distinction exigences obligatoires et compétences souhaitées	OK
S3-11	Validation des recruteurs	Comptes soumis à l'approbation d'un administrateur	OK
S3-12	Suppression réversible	Corbeille avec restauration, protection des comptes sensibles	OK
S3-04	Corpus d'apprentissage	—	Écarté
S3-06	Modèle supervisé	—	Écarté
S3-07	Audit de biais	Vérification de l'absence de corrélations non pertinentes	Sprint 4

Les tâches S3-09 à S3-12 ne figuraient pas au périmètre initial ; leur justification est exposée en section 6. Les tâches S3-04 et S3-06 ont fait l'objet d'une décision de non-réalisation, également motivée en section 6.

3.3 Indicateurs de réalisation

Indicateur	Valeur
Écrans livrés	18
Points d'accès de l'interface de programmation	38
Tests automatisés (tous réussis)	69
Analyse statique du code	sans anomalie
Compétences du référentiel métier	45
Durée d'analyse d'un curriculum vitæ	moins de 3 secondes

4 Chaîne d'analyse d'une candidature

4.1 Vue d'ensemble

La figure 1 présente l'enchaînement des traitements appliqués à chaque document déposé.




Figure 1: Chaîne de traitement, du dépôt du document à la décision humaine.

4.2 Lecture du document

La lecture procède par étapes successives. Le texte est d’abord extrait directement de la couche textuelle du document, méthode rapide et fidèle qui convient à la grande majorité des curriculum vitæ. Lorsque le document ne contient aucun texte exploitable — cas d’un document numérisé, constitué d’images — la reconnaissance optique de caractères prend le relais. Les documents au format Word sont également acceptés, y compris lorsque leur mise en page repose sur des tableaux.

Ce choix d’une cascade plutôt que d’une reconnaissance optique systématique répond à une réalité de terrain : appliquer l’OCR à un document déjà textuel dégraderait la qualité du résultat et multiplierait le temps de traitement.

4.3 Reconstitution du profil

Le document est ensuite découpé en sections — expérience, formation, compétences, certifications, langues — à partir d’une liste d’intitulés français et anglais. Cette étape conditionne la fiabilité de tout ce qui suit : une date figurant dans la rubrique « formation » ne doit pas alimenter le calcul de l’expérience professionnelle.

Chaque section est ensuite exploitée pour reconstituer un profil structuré : coordonnées du candidat, postes occupés avec leur intitulé, leur employeur et leurs dates, diplômes avec leur niveau, certifications avec leur organisme, et langues dont le niveau est ramené à l’échelle européenne commune de référence. Le schéma retenu reprend les blocs du format d’échange de fait dans l’industrie du recrutement, ce qui garantit l’interopérabilité du profil produit.

La durée totale d’expérience est calculée à partir des périodes reconstituées, en fusionnant celles qui se chevauchent : deux postes occupés simultanément ne sont pas comptés deux fois.

4.4 Calcul de la note

La note finale combine cinq composantes, dont le total est toujours égal à cent afin que les candidatures restent comparables entre elles :

Composante	Poids	Origine
Compétences obligatoires	35	Référentiel métier appliqué au texte
Compétences souhaitées	10	Idem, sans caractère bloquant
Proximité sémantique	25	Comparaison du sens du document et de l’offre
Années d’expérience	20	Périodes reconstituées
Niveau de diplôme	10	Rubrique formation

Lorsqu’une composante ne peut être calculée, son poids est reporté sur les compétences obligatoires : le total reste sur cent en toutes circonstances.

Les **critères éliminatoires** définis par l’offre — expérience minimale, diplôme minimal, compétence indispensable — plafonnent la note à quarante-cinq points et conservent le motif exact du déclassement.

Listing 1: Traçage du motif : condition de l'explicabilité de la note.

```

if offre.min_experience_years and experience < offre.min_experience_years:
    eliminatoires.append(
        f"Experience {experience} an(s) < "
        f"{offre.min_experience_years} an(s) requis"
    )
if manquantes:
    eliminatoires.append(
        "Compétence(s) obligatoire(s) absente(s) : " + ", ".join(manquantes)
    )

```

4.5 Comportement en cas d'échec

Une candidature dont le document n'a pas pu être lu n'est jamais perdue ni pénalisée : elle est signalée comme dépourvue de note, distinctement des candidatures écartées, et le recruteur peut relancer l'analyse ou saisir le profil manuellement. Cette distinction évite d'imputer au candidat une insuffisance qui ne serait en réalité qu'un défaut de traitement.

De la même manière, chaque brique technique dispose d'une solution de repli : en l'absence du modèle sémantique, une comparaison lexicale prend le relais ; en l'absence de reconnaissance optique, seuls les documents textuels sont analysés. Le service reste opérationnel dans tous les cas.

5 La plateforme en fonctionnement

Les captures qui suivent proviennent de la plateforme alimentée par un jeu de démonstration : huit offres, dix-huit candidatures et des documents réels traités par la chaîne d'analyse décrite ci-dessus.

5.1 Espace du recruteur




Figure 2: Tableau de bord du recruteur. Les indicateurs, l'entonnoir de conversion et la courbe d'activité sont calculés à partir des données de la base ; le sélecteur de période recalcule l'ensemble.




Figure 3: Candidatures classées par note décroissante. Les onglets matérialisent la règle de présélection : liste restreinte, ensemble des candidatures, candidatures écartées, candidatures sans note.

5.2 Explication d’une note

L’explicabilité constitue l’exigence centrale du projet : le recruteur doit pouvoir comprendre l’origine de chaque note, et le candidat obtenir une justification en cas de refus.

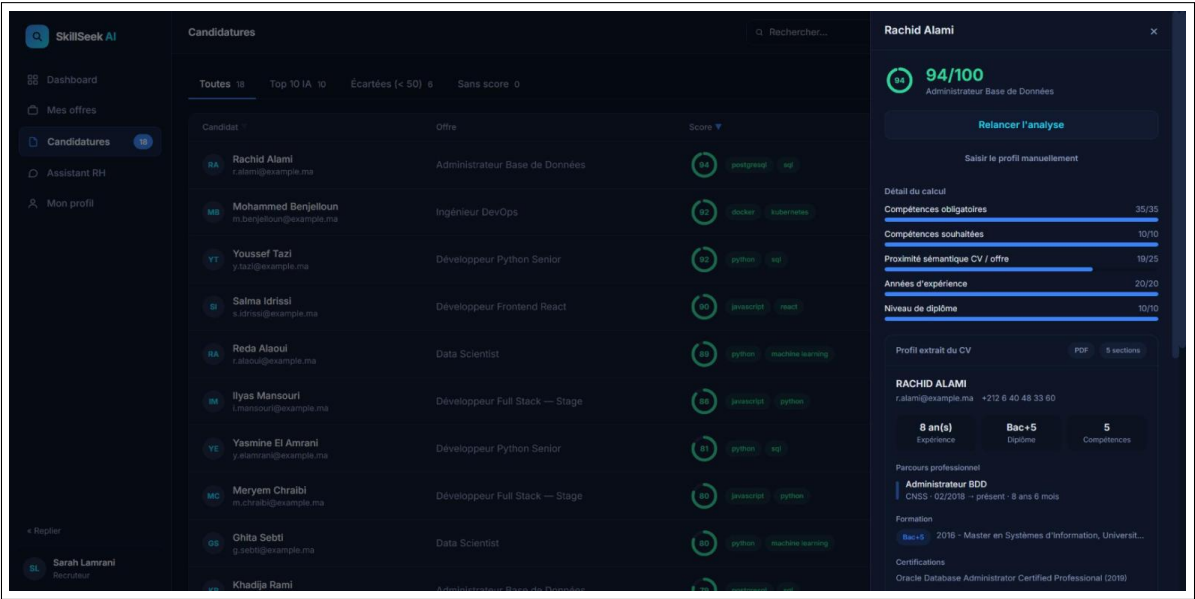


Figure 4: Détail d’une note élevée. Les cinq composantes du calcul sont détaillées, puis le profil reconstitué depuis le document : coordonnées, durée d’expérience, niveau de diplôme, parcours professionnel daté.




Figure 5: Suite du panneau : formation, certifications avec leur organisme, langues avec leur niveau européen, compétences détectées, puis confrontation aux exigences de l'offre et actions de décision.

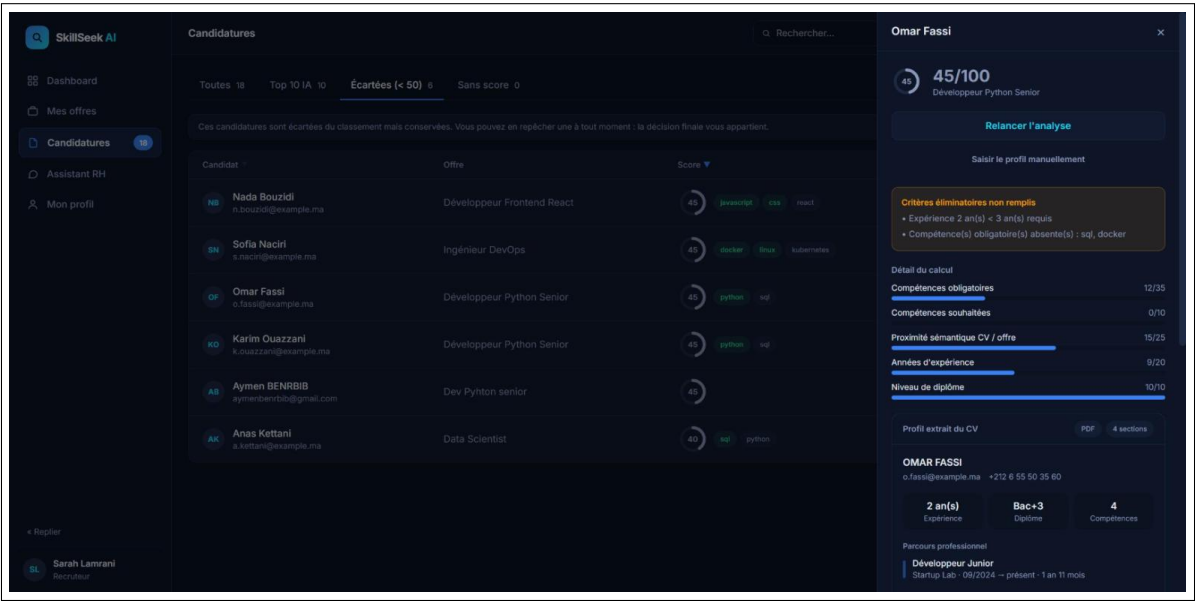


Figure 6: Candidature écartée. Les motifs exacts sont affichés — insuffisance d'expérience et absence de compétences obligatoires — et le détail du calcul montre la part obtenue sur chaque composante. La candidature reste consultable et repêchable.

5.3 Assistant et gestion des offres

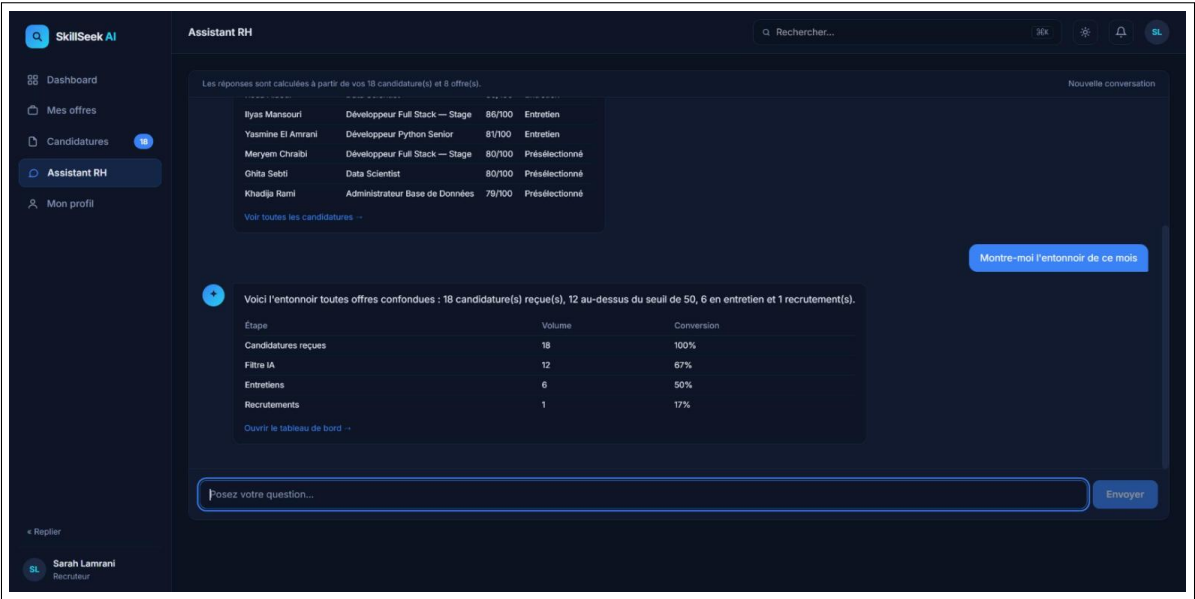


Figure 7: Assistant conversationnel. Les réponses sont calculées sur les données réelles de la plateforme et restituées sous forme de tableaux, avec un accès direct à l'écran concerné.




Figure 8: Gestion des offres publiées, avec le nombre de candidatures reçues et la note moyenne obtenue par offre.

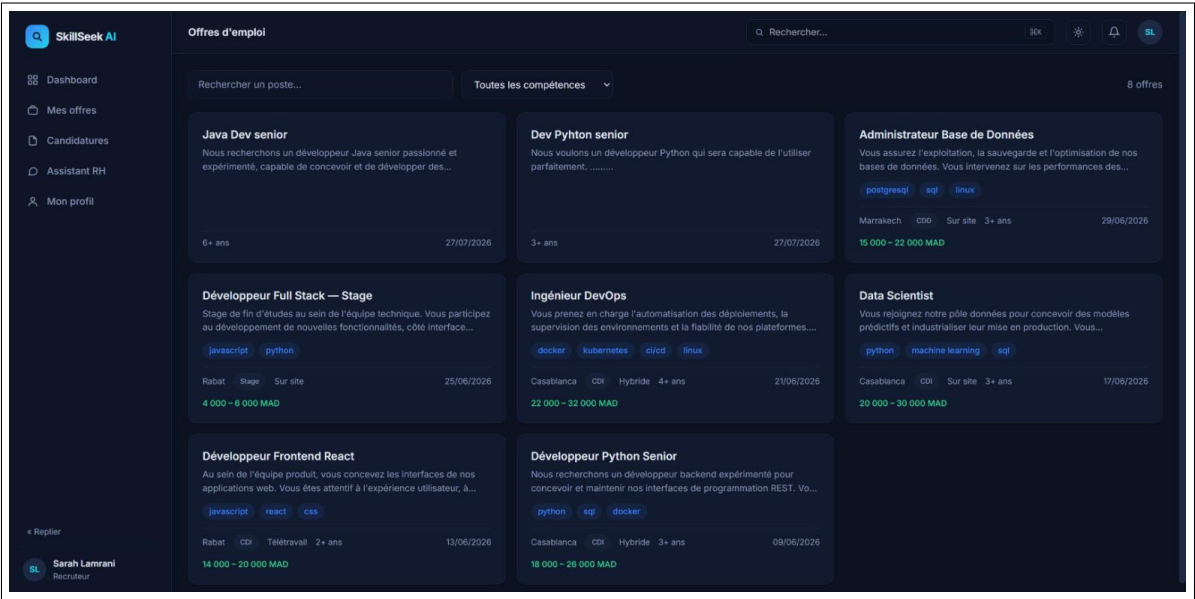


Figure 9: Liste des offres telle que présentée aux candidats : localisation, type de contrat, mode de travail, fourchette de rémunération et compétences attendues.

5.4 Espace du candidat




Figure 10: Suivi d'une candidature par le candidat. L'avancement est présenté par étapes ; la note attribuée par le système n'est volontairement pas exposée, celle-ci relevant de l'appréciation interne du recruteur.

5.5 Espace d'administration




Figure 11: Tableau de bord de l'administrateur : répartition des comptes, volumes, et mise en évidence des demandes appelant une décision.

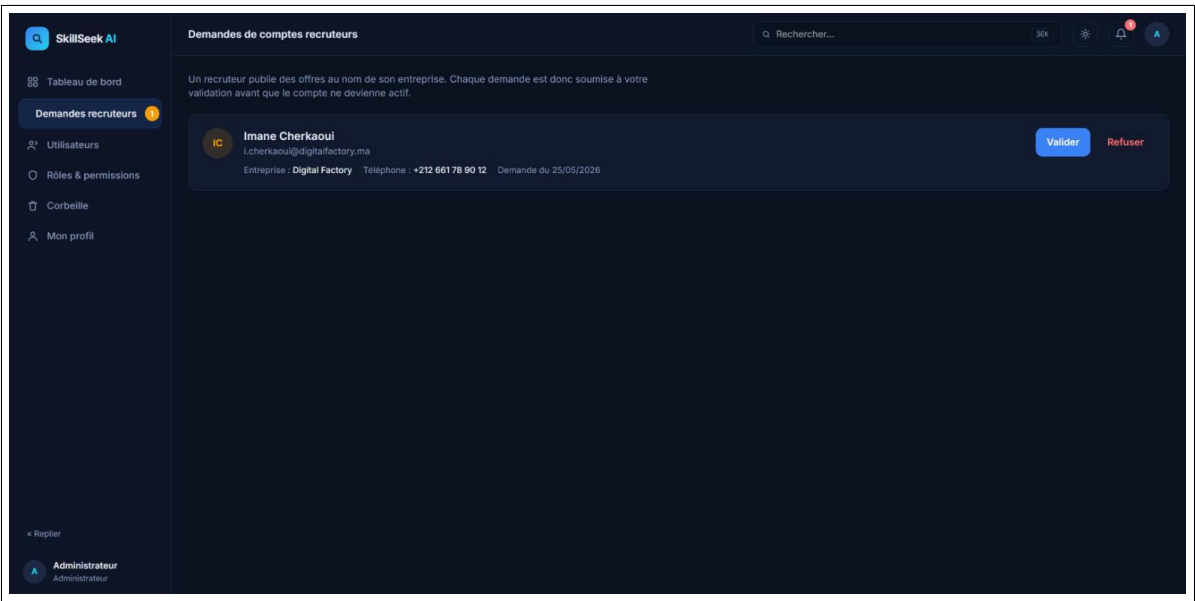


Figure 12: Validation des comptes recruteurs. Publier une offre engage l'entreprise représentée : chaque demande est donc soumise à l'approbation d'un administrateur, avec possibilité de refus motivé.

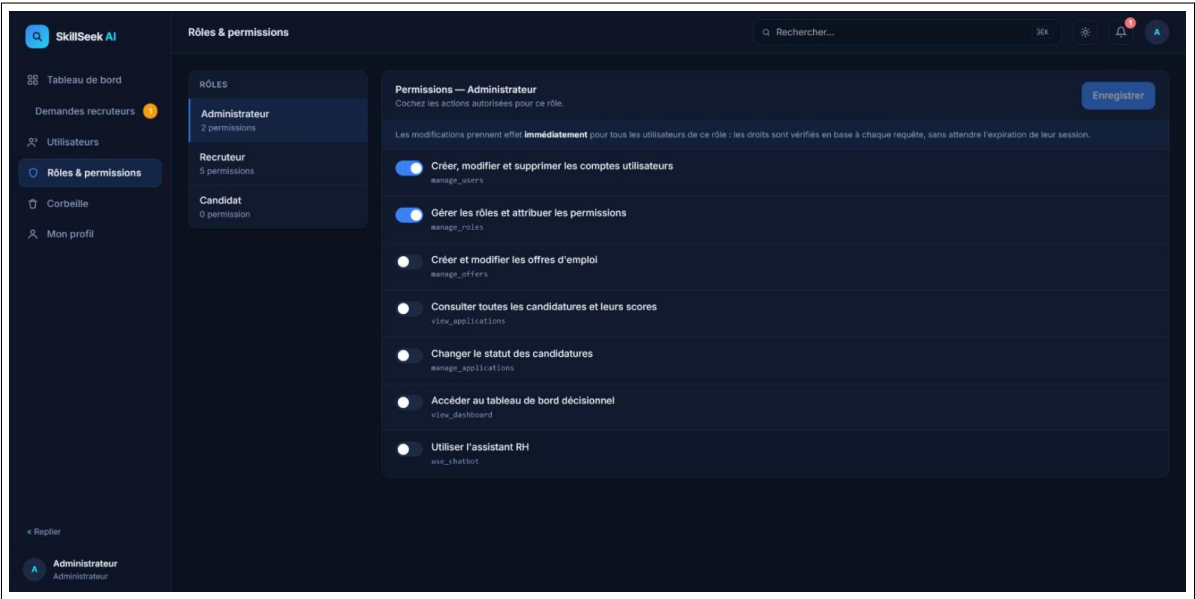


Figure 13: Matrice des droits. Toute modification s’applique immédiatement aux utilisateurs du rôle concerné, les permissions étant vérifiées en base à chaque requête.

5.6 Accessibilité




Figure 14: Thème clair. L’ensemble des écrans est déclinable en deux thèmes, le choix étant conservé d’une session à l’autre et la préférence du système d’exploitation respectée par défaut.

6 Choix structurants et justifications

6.1 Renoncement à l’apprentissage supervisé

Le cahier des charges prévoyait un modèle de classification entraîné sur un corpus de curriculum vitæ étiquetés. Ce corpus n’existait pas et sa constitution représentant à elle seule plusieurs jours de travail au résultat incertain, la décision a été prise de fonder le classement sur la combinaison des règles métiers et de la proximité sémantique.

Ce choix est assumé et présente des avantages propres. Un modèle statistique produit une note dont l’origine est difficile à restituer ; l’approche retenue permet au contraire d’expliquer

chaque point attribué, ce qui répond directement à l'exigence de transparence du projet et aux obligations réglementaires en matière de décision assistée par algorithme. Le module de score conserve par ailleurs une interface stable : l'ajout ultérieur d'un modèle supervisé ne remettrait pas en cause l'architecture existante.

6.2 Adoption des conventions professionnelles d'analyse de CV

L'extraction initialement prévue se limitait à relever des mots-clés. L'expérimentation sur des documents réels a montré les limites de cette approche : sans reconstitution du parcours, il devient impossible de distinguer trois années d'expérience pertinente d'une mention isolée dans une liste de compétences.

L'analyse produit désormais un profil structuré complet, conforme aux pratiques des systèmes professionnels de suivi des candidatures. La distinction entre compétences obligatoires et compétences souhaitées, également issue de ces pratiques, rend le classement nettement plus fidèle aux attentes réelles d'un recruteur.

6.3 Renforcement de la gouvernance des comptes

Deux ajouts ont été effectués en cours de sprint. Les comptes recruteurs sont désormais soumis à validation, la publication d'offres engageant l'entreprise représentée. Les suppressions sont devenues réversibles, avec une corbeille permettant la restauration ; la suppression définitive est par ailleurs refusée sur une offre ayant reçu des candidatures, la traçabilité primant sur le nettoyage.

7 Vérification

La couverture de tests a été portée de vingt-cinq à soixante-neuf cas, tous réussis.

Domaine testé	Cas	Résultat
Authentification et sessions	6	Réussis
Contrôle d'accès	3	Réussis
Moteur de notation et règle de présélection	6	Réussis
Offres, tableau de bord, profil	5	Réussis
Notifications et cloisonnement	5	Réussis
Analyse linguistique et sémantique	14	Réussis
Reconstitution du profil structuré	16	Réussis
Validation des comptes et corbeille	14	Réussis
Total	69	100 %

Au-delà des tests unitaires, la cohérence du classement a été contrôlée sur un ensemble de profils dont la qualité attendue était connue à l'avance. Les notes obtenues respectent l'ordre attendu, avec un écart net entre les catégories, ce qui confirme le pouvoir discriminant du moteur.

Qualité attendue du profil	Note moyenne	Effectif
Profil très adapté	88 / 100	6
Profil adapté	76 / 100	5
Profil partiellement adapté	45 / 100	3
Profil non adapté	37 / 100	2

8 Planification

Sprint	Contenu	Période	Durée
1	Socle technique, base de données, sécurité	06/07 – 15/07	10 jours
2	Interface, parcours métier, notifications	16/07 – 27/07	12 jours
3	Analyse des CV, classement explicable	28/07 – 06/08	10 jours
4	Décisionnel, indicateurs, finalisation	07/08 – 16/08	10 jours




Figure 15: Avancement du projet à la clôture du Sprint 3.

8.1 Contenu du Sprint 4

Les travaux restants portent sur la restitution décisionnelle et la finalisation :

- rapports décisionnels sous Power BI, connectés à la base de données ;
- mesure des indicateurs de performance annoncés au cahier des charges ;
- vérification de l'absence de corrélation entre les notes et des attributs non pertinents ;
- tests de bout en bout des parcours critiques ;
- documentation d'exploitation et préparation de la soutenance.

9 Risques et mesures

Risque	Criticité	Mesure retenue
Diversité des mises en page de curriculum vitæ	Moyenne	Découpage en sections avec mode de repli ; toute candidature illisible reste traitable manuellement.
Absence de modèle supervisé	Moyenne	Choix assumé et documenté ; l'explicabilité du dispositif retenu compense l'absence d'apprentissage statistique.
Densité du Sprint 4	Moyenne	Priorisation : les indicateurs et le décisionnel prennent sur la mise en ligne distante, remplaçable par une démonstration conteneurisée.
Coût des services externes	Faible	Sélection exclusive d'outils gratuits ou en licence libre pour l'ensemble de la chaîne.

10 Conclusion

Le Sprint 3 est clôturé conformément au calendrier. La plateforme remplit désormais sa fonction première : un curriculum vitæ déposé est lu automatiquement, quel que soit son format, décomposé en un profil structuré, confronté aux exigences de l'offre, et noté selon un calcul dont chaque élément est restitué au recruteur.

Le renoncement à l'apprentissage supervisé, décidé en début de sprint, s'est révélé bénéfique au-delà du seul gain de temps : il a conduit à concentrer l'effort sur la qualité de l'extraction et sur la transparence du classement, qui constituent la véritable valeur du dispositif. Un système

capable de justifier chaque décision répond mieux aux besoins d'un recruteur — et aux obligations réglementaires — qu'un modèle statistique dont les résultats resteraient inexplicables.

Le Sprint 4 sera consacré à la restitution décisionnelle, à la mesure des indicateurs annoncés et à la préparation de la livraison finale.