



École des Sciences de l'Information (ESI)
Filière : Ingénierie des Systèmes d'Information et Transformation Digitale (ISITD)

Rapport d'avancement

Sprint 4

SkillSeek AI

Plateforme intelligente de gestion du recrutement
Apprentissage supervisé et évaluation des performances

Auteur : Aymen Benbib

Organisme d'accueil : BC SKILLS

Table des matières

1	Objet du rapport	2
2	Rappel des sprints précédents	2
3	Synthèse de l'avancement	2
3.1	État global	2
3.2	Tâches du Sprint 4	3
3.3	Indicateurs de réalisation	3
4	Reprise de l'apprentissage supervisé	3
4.1	Motif de la révision	3
4.2	Le corpus retenu	4
4.3	Ce que le modèle observe	4
4.4	Enchaînement du traitement	5
5	Protocole d'évaluation	5
5.1	Pourquoi quatre protocoles	5
5.2	Le découpage strict	5
5.3	Deux erreurs de mesure détectées	6
5.3.1	Une fuite de données dans le découpage fourni	6
5.3.2	Un indicateur parasite	6
5.4	Une question mal posée	6
6	Résultats	6
6.1	Performances par protocole	7
6.2	Lecture des résultats	7
6.3	Ce sur quoi le modèle fonde son jugement	8
7	Intégration à la plateforme	8
7.1	Un ajustement, non une composante	8
7.2	Les règles restent souveraines	8
7.3	Organisation des modules	9
7.4	Restitution au recruteur	9
8	Vérification	10
9	Travaux restants	11
9.1	Mesure des indicateurs du cahier des charges	11
9.2	Audit de biais	11
9.3	Restitution décisionnelle et finalisation	11
10	Planification	11
11	Risques et mesures	12
12	Conclusion	12

1 Objet du rapport

Ce document présente l'état d'avancement du projet **SkillSeek AI** à mi-parcours du Sprint 4, dernier sprint du stage. Il rend compte du fait marquant de la période : la **reprise de l'apprentissage supervisé**, écarté au Sprint 3 faute de corpus, désormais réalisé, évalué et intégré à la plateforme.

Une place importante y est donnée à la méthode d'évaluation. Un modèle d'apprentissage se juge moins à la performance qu'il affiche qu'au protocole qui l'établit : ce rapport expose donc les quatre protocoles appliqués, les deux erreurs de mesure qu'ils ont permis de détecter, et le chiffre finalement retenu — modeste et vérifié plutôt que flatteur et fragile.

2 Rappel des sprints précédents

Le **Sprint 1** (06/07 – 15/07) a livré le socle technique : environnement conteneurisé, intégration continue, modèle de données, authentification par jeton et contrôle d'accès par rôles appliqué en temps réel.

Le **Sprint 2** (16/07 – 27/07) a livré l'interface complète — dix-huit écrans répartis entre les trois profils d'utilisateurs — les parcours métier de bout en bout et les notifications événementielles.

Le **Sprint 3** (28/07 – 06/08) a livré le cœur analytique : lecture des documents avec reconnaissance optique en repli, reconstitution d'un profil structuré selon les conventions professionnelles d'analyse de curriculum vitæ, moteur de règles à critères éliminatoires tracés, proximité sémantique multilingue, et assistant conversationnel fondé sur les données réelles de la plateforme.

Point de départ du Sprint 4. Le rapport du Sprint 3 actait le renoncement à l'apprentissage supervisé, motivé par l'absence de corpus étiqueté disponible. Cette décision a été révisée au début du présent sprint ; la section 4 en expose les raisons et les conséquences.

3 Synthèse de l'avancement

3.1 État global

Sprint	Période	État	Périmètre
Sprint 1	06/07 – 15/07	Terminé	Socle technique, base de données, sécurité
Sprint 2	16/07 – 27/07	Terminé	Interface, parcours métier, notifications
Sprint 3	28/07 – 06/08	Terminé	Analyse des CV, classement explicable
Sprint 4	07/08 – 16/08	En cours	Apprentissage supervisé, décisionnel, finalisation

Avancement global estimé : **92 %** du périmètre fonctionnel. La totalité des fonctions du cahier des charges est désormais réalisée, y compris le module d'apprentissage initialement abandonné. Les travaux restants portent sur la restitution décisionnelle et sur la mesure formelle des indicateurs.

3.2 Tâches du Sprint 4

ID	Tâche	Livrable vérifié	État
S3-04	Corpus d'apprentissage	8 000 appariements étiquetés, exploitables après contrôle	OK
S3-06	Modèle supervisé	Classifieur binaire, 17 indicateurs, évalué sous 4 protocoles	OK
S4-01	Intégration au score	Ajustement borné, règles métiers souveraines	OK
S4-02	Robustesse du dispositif	Fonctionnement garanti en l'absence de modèle	OK
S3-07	Audit de biais	Corrélation entre notes et attributs non pertinents	En cours
S4-03	Décisionnel Power BI	Rapports recruteur et direction	En cours
S4-04	Indicateurs du cahier des charges	Précision et rappel du dispositif complet	En cours
S4-05	Tests de bout en bout	Parcours candidat, recruteur, administrateur	En cours
S4-07	Documentation et soutenance	Guide d'exploitation, support de présentation	En cours

Les tâches S3-04 et S3-06, déclarées écartées au Sprint 3, ont été réintégrées et achevées. La tâche S4-01 ne figurait pas au périmètre initial : elle est la conséquence directe de cette réintégration.

3.3 Indicateurs de réalisation

Indicateur	Sprint 3	Aujourd'hui
Écrans livrés	18	18
Points d'accès de l'interface de programmation	38	38
Tests automatisés (tous réussis)	69	93
Analyse statique du code	sans anomalie	sans anomalie
Appariements du corpus d'apprentissage	—	8 000
Indicateurs calculés par appariement	—	17
Durée d'analyse d'un curriculum vitæ	< 3 s	< 3 s

L'ajout du modèle n'a pas dégradé le temps de traitement : la prédiction s'appuie sur des indicateurs déjà calculés par la chaîne d'analyse existante, et le modèle n'est chargé qu'une seule fois au démarrage du service.

4 Reprise de l'apprentissage supervisé

4.1 Motif de la révision

Le renoncement acté au Sprint 3 reposait sur un constat : aucun corpus de curriculum vitæ étiquetés n'avait été identifié, et sa constitution manuelle représentait plusieurs jours de travail au résultat incertain.

Sur indication de l'encadrement, la recherche a été reprise sur les plateformes publiques de partage de jeux de données. Un corpus d'appariements entre curriculum vitæ et descriptions de poste, chaque paire portant un jugement d'adéquation, y a été identifié. La condition qui fondait le renoncement n'était donc plus vérifiée, et la décision a été révisée.

Deux corpus candidats ont d'abord été écartés après contrôle : le premier ne présentait aucun signal exploitable, un modèle entraîné dessus faisant moins bien que la simple prédiction de la classe majoritaire ; le second décrivait des décisions postérieures à l'entretien, information dont un système de présélection ne dispose pas au moment où il opère. Ce contrôle préalable de la

pertinence du corpus est une étape à part entière : un modèle appris sur des données qui ne correspondent pas à l'usage visé produit des résultats sans valeur, quelle que soit sa performance apparente.

4.2 Le corpus retenu

Caractéristique	Valeur
Appariements (curriculum vitæ, offre) étiquetés	8 000
Curriculum vitæ distincts	643
Offres distinctes	351
Proportion de profils jugés convenables	49,6 %
Langue des documents	anglais

Un **jeu de validation francophone** distinct a par ailleurs été constitué pour ce projet : quatre offres et douze curriculum vitæ rédigés en français, formant vingt-quatre appariements. Il n'intervient jamais dans l'apprentissage et sert exclusivement à vérifier que le modèle, appris sur des documents anglais, reste opérant sur des documents français.

4.3 Ce que le modèle observe

Le modèle ne reçoit pas les textes bruts mais dix-sept indicateurs calculés pour chaque paire. Le principe de conception retenu est que **tous les indicateurs sont relationnels** : chacun décrit un rapport entre le profil et l'exigence, jamais une propriété absolue du document.

Famille	Nombre	Contenu
Proximité de sens	3	Similarité globale, similarité des compétences, similarité des intitulés de poste
Adéquation des compétences	5	Part des exigences satisfaites, recouvrement, nombre de compétences communes, exigences manquantes, part du profil utile à l'offre
Adéquation de l'expérience	3	Rapport, écart en années, suffisance
Adéquation du diplôme	2	Écart de niveau, suffisance
Richesse du profil	4	Compétences, postes, certifications, langues

Ce choix a une conséquence directe sur la portabilité linguistique. Les indicateurs de proximité de sens reposent sur une représentation vectorielle multilingue : deux phrases de même sens exprimées en deux langues différentes y occupent des positions voisines. Un modèle appris sur des indicateurs de ce type n'apprend donc pas l'anglais, mais l'adéquation — ce que confirme le protocole 4.

4.4 Enchaînement du traitement




Figure 1: De la donnée étiquetée à la note affichée au recruteur. La vectorisation est assurée par le même module à l'apprentissage et en service : c'est la condition pour que le modèle observe exactement la même chose dans les deux situations.

5 Protocole d'évaluation

5.1 Pourquoi quatre protocoles

Une même performance peut être élogieuse ou trompeuse selon la manière dont on sépare les données d'apprentissage et de test. Quatre protocoles ont donc été appliqués, du plus permissif au plus exigeant, afin de mesurer l'écart entre ce qu'un protocole complaisant laisse croire et ce qu'un protocole rigoureux établit.

N°	Protocole	Ce qu'il mesure
1	Découpage d'origine	Traiter une offre nouvelle avec des profils déjà rencontrés
2	Découpage par CV	Traiter un candidat inconnu sur des offres déjà connues
3	Découpage strict	Traiter un candidat inconnu sur une offre nouvellement publiée — situation réelle de la plateforme
4	Validation française	Vérifier que le transfert d'une langue à l'autre opère

5.2 Le découpage strict

Le protocole 3 est celui qui fonde le chiffre retenu. Il exige que ni le curriculum vitæ ni l'offre du jeu de test n'aient été rencontrés à l'apprentissage. Cette double condition réduit fortement le volume exploitable — les paires dont un seul des deux éléments est connu sont écartées — mais elle seule reproduit la situation d'exploitation.




Figure 2: Découpage strict. Seules les paires dont *les deux* éléments sont inconnus constituent le jeu de test. Les deux quadrants gris sont écartés : les y inclure reviendrait à évaluer le modèle sur des documents qu'il a déjà mémorisés.

5.3 Deux erreurs de mesure détectées

5.3.1 Une fuite de données dans le découpage fourni

Le corpus était livré avec une séparation apprentissage/test préétablie. Un contrôle a révélé que cette séparation portait sur les offres uniquement : **476 des 477 curriculum vitæ du jeu de test figuraient également dans le jeu d'apprentissage**. Toute performance mesurée sur ce découpage récompense donc en partie la mémorisation des documents plutôt que la capacité à juger.

Ce constat n'invalide pas le corpus : il invalide le découpage. D'où la construction des protocoles 2 et 3.

5.3.2 Un indicateur parasite

Une première version des indicateurs incluait la longueur du curriculum vitæ et celle de l'offre. Ces deux mesures ressortaient parmi les plus contributives, ce qui a mis la puce à l'oreille : la longueur d'une annonce ne dit rien de l'adéquation d'un candidat, mais elle identifie l'annonce. Le modèle avait trouvé un raccourci — reconnaître l'offre plutôt que d'évaluer le profil.

Les deux indicateurs ont été supprimés. Le principe énoncé plus haut, selon lequel tout indicateur doit être relationnel, découle directement de cette observation.

5.4 Une question mal posée

Le corpus distingue trois niveaux : profil convenable, profil pouvant convenir, profil ne convenant pas. Sous protocole strict, le modèle n'apportait sur cette formulation **aucun gain mesurable** : +0,4 point d'exactitude sur la référence, c'est-à-dire rien.

Plutôt que d'accepter ce résultat ou de le maquiller, six configurations ont été comparées afin d'en identifier la cause.

Configuration	Gain	Exactitude	F1
Indicateurs — 2 classes	+8,5 %	61,9 %	0,619
Combinaison — 2 classes	+3,9 %	57,4 %	0,571
Indicateurs — 3 classes	+0,4 %	46,9 %	0,421
Représentation complète — 3 classes	+0,4 %	46,9 %	0,247
Représentation complète — 2 classes	-0,6 %	52,9 %	0,525
Représentation complète — 2 classes, modèle linéaire	-2,2 %	51,3 %	0,509

Deux enseignements en découlent.

La distinction entre « convient » et « pourrait convenir » n'est pas apprenable ici. Elle relève d'une appréciation subjective que six cent quarante-trois curriculum vitæ ne suffisent pas à faire saisir. Ramenée à deux classes, la frontière devient nette et le modèle apprend.

La représentation complète des documents échoue. Remplacer les dix-sept indicateurs par la représentation vectorielle intégrale des deux textes — plus de quinze cents dimensions — dégrade les résultats au lieu de les améliorer. Le corpus est trop petit relativement à cette dimension : le modèle y trouve des régularités qui n'existent que dans les exemples d'apprentissage. Les dix-sept indicateurs, en concentrant l'information utile, protègent de cet écueil.

La formulation binaire a donc été retenue : **le profil convient, ou il ne convient pas**.

6 Résultats

6.1 Performances par protocole

Protocole	Exactitude	Référence	Gain	F1	AUC
1 — Découpage d'origine	59,8 %	51,3 %	+8,5 %	0,614	0,629
2 — Découpage par CV	65,4 %	51,8 %	+13,6 %	0,664	0,693
3 — Découpage strict	61,9 %	53,4 %	+8,5 %	0,627	0,653
4 — Validation française	79,2 %	66,7 %	+12,5 %	0,762	0,938




Figure 3: Exactitude du modèle comparée à la référence, protocole par protocole. L'écart entre les deux barres est la seule quantité qui compte : une exactitude élevée sur des classes déséquilibrées ne prouve rien.

6.2 Lecture des résultats

Le protocole 3 est celui qui doit être retenu : **61,9 % d'exactitude contre 53,4 % pour la référence, soit un gain de 8,5 points**, avec un F1 de 0,627 et une aire sous la courbe ROC de 0,653. C'est un résultat modeste, mais mesuré dans les conditions les plus défavorables et les plus fidèles à l'usage réel.

Le protocole 2 affiche un gain supérieur (+13,6 points) parce qu'il autorise le modèle à retrouver au test des offres déjà rencontrées. L'écart entre les protocoles 2 et 3 — cinq points — chiffre précisément ce qu'un protocole permissif fait gagner artificiellement.

Le protocole 4 mérite une réserve explicite. Ses 79,2 % d'exactitude et son AUC de 0,938 portent sur **vingt-quatre appariements seulement**. Ce protocole établit que le transfert d'une langue à l'autre opère — un modèle appris sur des documents anglais reste utilisable sur des curriculum vitæ français — mais il ne constitue pas une mesure de précision, et il ne sera pas présenté comme telle.

6.3 Ce sur quoi le modèle fonde son jugement




Figure 4: Contribution des dix indicateurs les plus déterminants. Tous décrivent une relation entre le profil et l'exigence : aucun ne permet au modèle d'identifier le document plutôt que d'en juger l'adéquation.

Cette répartition constitue une vérification en soi. Les quatre indicateurs de tête — similarité des compétences, similarité globale, écart d'expérience, similarité des intitulés — sont exactement ceux qu'un recruteur mobiliserait. Aucun raccourci parasite ne subsiste, contrairement à la première version du dispositif.

7 Intégration à la plateforme

7.1 Un ajustement, non une composante

Le modèle aurait pu se voir attribuer une part fixe de la note, au même titre que les cinq composantes existantes. Ce choix a été écarté : un gain de 8,5 points d'exactitude ne justifie pas de lui confier vingt ou vingt-cinq points sur cent.

Le modèle applique donc un **ajustement borné à ± 8 points** sur la note établie par les règles. Une probabilité de 0,5 — le modèle est sans avis — laisse la note inchangée ; une probabilité de 1 ajoute huit points, une probabilité nulle en retire autant. La structure sur cent points, et donc la comparabilité des candidatures, est intégralement préservée.

Composante	Poids	Origine
Compétences obligatoires	35	Référentiel métier appliqué au texte
Compétences souhaitées	10	Idem, sans caractère bloquant
Proximité sémantique	25	Comparaison du sens du document et de l'offre
Années d'expérience	20	Périodes reconstituées
Niveau de diplôme	10	Rubrique formation
<i>Avis du modèle appris</i>	± 8	<i>Ajustement, appliqué après le calcul</i>

7.2 Les règles restent souveraines

Trois garanties encadrent l'intervention du modèle.

1. **Aucun rattrapage.** Une candidature écartée par un critère éliminatoire — expérience insuffisante, diplôme insuffisant, compétence obligatoire absente — n'est jamais repêchée par le modèle. La décision repose alors sur un motif explicite, qu'aucun avis statistique ne doit pouvoir renverser.
2. **Aucune dépendance.** Modèle absent, illisible, ou entraîné sur d'autres indicateurs : la note est calculée sans cette composante et l'analyse aboutit normalement. Le contrôle porte sur la liste exacte des indicateurs attendus, de sorte qu'un modèle périmé soit refusé plutôt qu'exploité de travers.

3. **Aucune opacité.** La probabilité, la note avant ajustement et l'ajustement effectivement appliqué sont restitués au recruteur.




Figure 5: Séquence d'analyse d'une candidature. Le modèle est interrogé avant le calcul, mais son avis n'est appliqué qu'après les critères éliminatoires : l'ordre garantit qu'il ne peut jamais les contourner.

7.3 Organisation des modules




Figure 6: Place du nouveau module dans l'architecture. Il s'insère en fin de chaîne d'analyse et alimente le moteur de score, sans modification des modules existants.

7.4 Restitution au recruteur

L'exigence d'explicabilité, centrale depuis le début du projet, s'applique au modèle comme au reste. Le panneau de détail d'une candidature affiche désormais, sous les cinq composantes du calcul, la probabilité estimée, la note obtenue par les seules règles et l'ajustement appliqué.

Listing 1: L'ajustement n'est calculé que si aucun critère éliminatoire n'est déclenché.

```

ajustement = 0.0
if probabilite_modele is not None and not eliminatoires:
    ajustement = (probabilite_modele - 0.5) * 2 * AMPLITUDE_MODELE

score = round(score_regles + ajustement)
if eliminatoires:
    score = min(score, 45)  # ecarte par regle metier
  
```




Figure 7: Détail d'une note, tel que présenté au recruteur. Sous les cinq composantes du calcul figure l'avis du modèle : probabilité que le profil convienne, note établie par les règles et ajustement effectivement appliqué avec sa borne. La note affichée, 96, est la somme vérifiable de 92 et de 3,8.

8 Vérification

La couverture de tests a été portée de soixante-neuf à **quatre-vingt-treize** cas, tous réussis.

Domaine testé	Cas	Résultat
Authentification et sessions	6	Réussis
Contrôle d'accès	3	Réussis
Moteur de notation et règle de présélection	10	Réussis
Modèle appris — robustesse	5	Réussis
Offres, tableau de bord, profil	5	Réussis
Notifications et cloisonnement	5	Réussis
Analyse linguistique et sémantique	14	Réussis
Reconstitution du profil structuré	16	Réussis
Assistant conversationnel	15	Réussis
Validation des comptes et corbeille	14	Réussis
Total	93	100 %

Les vingt-quatre cas ajoutés portent principalement sur les modes de défaillance du modèle. L'exigence testée n'est pas la qualité des prédictions — elle relève des protocoles d'évaluation — mais la garantie qu'**aucune analyse de candidature ne peut échouer à cause du modèle** : fichier absent, fichier corrompu, modèle entraîné sur d'autres indicateurs, chacun de ces cas est vérifié individuellement et doit aboutir à une note calculée sans cette composante.

Quatre cas vérifient par ailleurs les propriétés de l'ajustement : neutralité à probabilité 0,5, respect de la borne de ± 8 points, et impossibilité de rattraper une candidature écartée par une règle.

9 Travaux restants

9.1 Mesure des indicateurs du cahier des charges

Le cahier des charges annonce une précision supérieure ou égale à 85 % et un rappel supérieur ou égal à 80 %. Ces indicateurs portent sur le **dispositif de présélection dans son ensemble** — lecture du document, reconstitution du profil, règles métiers, calcul de la note — et non sur le seul modèle d'apprentissage, dont l'intervention se limite à huit points d'ajustement.

Cette distinction doit être établie sans ambiguïté dans le document final : rapprocher les 61,9 % du modèle des 85 % annoncés reviendrait à comparer deux grandeurs différentes. La mesure du dispositif complet sera conduite sur le jeu francophone, où la qualité attendue de chaque profil est connue à l'avance, et présentée avec le détail de son mode de calcul.

9.2 Audit de biais

Il s'agit de vérifier l'absence de corrélation entre les notes attribuées et des attributs sans rapport avec la compétence : marqueurs de genre, indices d'âge, origine perceptible du nom, établissement de formation. Le dispositif est favorable à ce contrôle, chaque note étant décomposée en composantes traçables : une corrélation anormale peut être rattachée à la composante qui la produit.

9.3 Restitution décisionnelle et finalisation

- rapports Power BI connectés à la base : vue recruteur (entonnoir de conversion, délais de traitement) et vue direction (volumes, taux de conversion, qualité des candidatures reçues) ;
- tests de bout en bout des trois parcours critiques ;
- notifications complémentaires sur les événements de cycle de vie des comptes ;
- guide d'exploitation et support de soutenance.

10 Planification




Figure 8 : Avancement du projet au 10 août. La livraison finale reste fixée au 16 août.

Période	Jours	Contenu
07/08 – 10/08	4	Corpus, modèle supervisé, protocoles d'évaluation, intégration au score, tests
11/08 – 13/08	3	Indicateurs du cahier des charges, audit de biais, tests de bout en bout
14/08 – 16/08	3	Rapports Power BI, documentation d'exploitation, préparation de la soutenance

11 Risques et mesures

Risque	Criticité	Mesure retenue
Performance modeste du modèle	Faible	Ajustement volontairement borné à ± 8 points : la qualité du classement ne dépend pas du modèle, qui n'apporte qu'un départage complémentaire.
Interprétation erronée des chiffres à la soutenance	Élevée	Distinction explicite, dans le rapport et à l'oral, entre l'exactitude du modèle et les indicateurs du dispositif complet ; chaque chiffre est présenté avec le protocole qui l'établit.
Volume restreint du jeu de validation français	Moyenne	Ce protocole est présenté comme une vérification de transfert linguistique, jamais comme une mesure de précision.
Densité de la fin de sprint	Moyenne	Priorisation : indicateurs et audit de biais avant les rapports décisionnels, ces derniers étant les plus aisément réductibles en cas de contrainte.
Coût des services externes	Faible	Chaîne complète construite sur des outils gratuits ou en licence libre ; aucun service payant n'est requis pour l'exécution.

12 Conclusion

La partie du Sprint 4 consacrée à l'apprentissage supervisé est achevée. La fonction déclarée abandonnée au sprint précédent est désormais réalisée : un corpus a été identifié puis contrôlé, dix-sept indicateurs relationnels ont été définis, un modèle a été entraîné, et son apport a été mesuré sous quatre protocoles dont le plus exigeant reproduit la situation réelle de la plateforme.

Le chiffre retenu — 8,5 points d'exactitude au-dessus de la référence — est modeste, et il est présenté comme tel. Il vaut davantage que les gains supérieurs qu'auraient affichés des protocoles plus permissifs : ceux-ci mesureraient en partie la mémorisation de documents déjà vus. Deux erreurs de mesure ont d'ailleurs été détectées et corrigées en cours de route, une fuite de données dans le découpage fourni et un indicateur permettant au modèle d'identifier l'offre au lieu de la juger.

L'intégration retenue tire les conséquences de cette mesure. Le modèle n'occupe pas une part fixe de la note mais applique un ajustement borné, ne peut jamais rattraper une candidature écartée par une règle explicite, et son absence n'empêche aucune analyse d'aboutir. La plateforme conserve ainsi la propriété qui fait sa valeur : chaque note attribuée reste intégralement justifiable auprès du recruteur comme auprès du candidat.

Les jours restants seront consacrés à la mesure des indicateurs annoncés au cahier des charges, à l'audit de biais, aux rapports décisionnels et à la préparation de la soutenance.